



Tarea 2: Aproximación con SVD y aplicaciones

Profesor: Felipe Urrutia

Ayudante: Luis Castillo

- Entrega por la plataforma Canvas. Cualquier duda enviar correo a `felipe.urrutia@uc.cl` con copia (CC) a `lpcastillo@uc.cl`.
- Duración: 1 semana. Fecha límite: 11-06-2026 hasta las 23:59.
- La entrega debe ser un archivo **PDF**. Puede ser generado en $\text{\LaTeX}$ u otra herramienta de su preferencia (por ejemplo, Typst u otro lenguaje).
- Las respuestas deben ser **sucintas**: claras, breves y precisas. Puede usar resultados vistos en clase siempre que los cite claramente.

P 1 (Pregunta Teórica). Demuestre la proposición 7.92 del libro *Linear Algebra Done Right* de Sheldon Axler, que establece que la mejor aproximación de rango k a una transformación $T \in \mathcal{L}(V, W)$ es dada por su descomposición en valores singulares (SVD). En clases vimos que dicha aproximación nos permite obtener

$$\|T - T_k\| = \sigma_{k+1},$$

Queda demostrar que en efecto σ_{k+1} es el menor error posible, es decir, para todo $S \in \mathcal{L}(V, W)$ con $\text{Dim}(\text{Range}(S)) \leq k$,

$$\|T - S\| \geq \sigma_{k+1}.$$

Indicación: Puede seguir la demostración del libro. Es importante que explique claramente cada paso de la demostración y cite los resultados que utilice.

P 2 (Pregunta Numérica). En esta pregunta aplicará SVD a un dataset de imágenes para explorar la estructura de baja dimensión que captura la descomposición.

Dataset. Elija **uno** de los siguientes datasets de imágenes en escala de grises (u otro de su preferencia, justificando la elección): Olivetti Faces, MNIST, Fashion-MNIST.

Construya la matriz de datos $X \in \mathbb{R}^{n \times d}$ donde cada fila es una imagen aplanada (d = número de píxeles). Centre los datos restando la imagen promedio $\bar{x}$ y aplique SVD:

$$\tilde{X} = X - \mathbf{1}\bar{x}^\top = U\Sigma V^\top.$$

Responda las siguientes partes:



- (a) **Valores singulares y varianza explicada.** Grafique los valores singulares $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ y la varianza explicada acumulada

$$\frac{\sum_{i=1}^k \sigma_i^2}{\sum_{i=1}^r \sigma_i^2}$$

en función de k . Indique cuántos componentes se necesitan para explicar el 90 % y el 99 % de la varianza. Interprete: ¿qué dice la curva sobre la estructura del dataset?

- (b) **Eigen-imágenes.** Muestre la imagen promedio $\bar{x}$ y las primeras 8–15 eigen-imágenes, es decir, los vectores $v_1, \dots, v_k$ (filas de V^T) reshaped a la dimensión original de cada imagen. Interprete al menos las primeras 3: ¿qué patrón visual captura cada una?
- (c) **Reconstrucción progresiva.** Tome una imagen de su dataset. Muestre su reconstrucción con distintos valores de k eigen-imágenes (elija valores que ilustren la mejora, e.g. $k = 1, 2, 3, 5, 10, 20, \dots$):

$$\hat{x}_k = \bar{x} + \sum_{i=1}^k z_i v_i, \quad z_i = \tilde{x}^T v_i.$$

Presente los resultados en una grilla donde cada columna corresponde a un valor de k y la última columna es la imagen original. Interprete a partir de qué k la reconstrucción es visualmente satisfactoria.

Entrega. Incluya en el PDF los gráficos y las interpretaciones de cada parte. Comparta además el notebook de Jupyter con el código utilizado (basta con un link a GitHub o similar en el PDF).